

Matriz de costos y decisión

Selección por tarea

Tarea	Recurso elegido	Justificación
Validación, duplicados y KPIs	Reglas y código n8n	Son operaciones deterministas; no requieren tokens ni razonamiento generativo.
Clasificación y borrador breve	Claude Haiku 4.5	Una sola inferencia resuelve ambas tareas con contexto acotado y revisión humana.
Autorización del contacto	Revisor en Gmail	La decisión comercial no se delega al modelo.
Lectura densa o proyectos complejos	Sonnet 5 o Sonnet 4.6, como alternativas	Solo se justificarían al incorporar documentos extensos o mayor razonamiento. No se utilizan en esta POC.
Análisis masivo no urgente	Message Batches, como alternativa	Adecuado para reclasificación histórica que tolere espera. No se utiliza en el flujo interactivo.

La solución implementa un modelo: Claude Haiku 4.5. Los otros modelos y Batch forman parte de la comparación económica, no de la ejecución demostrada.

Comparación económica

Precios en USD por millón de tokens, consultados el 6 de septiembre de 2026. Escenario homogéneo: 1.000 tokens de entrada y 400 de salida por solicitud; sin caché, reintentos ni herramientas adicionales.

Alternativa	Entrada / salida por millón	Costo por solicitud	Costo por 1.000 solicitudes
Haiku 4.5, síncrono - elegido	1,00 / 5,00	0,003 USD	3,00 USD
Sonnet 5, síncrono	2,00 / 10,00	0,006 USD	6,00 USD
Sonnet 4.6, síncrono	3,00 / 15,00	0,009 USD	9,00 USD
Haiku 4.5, Batch - alternativa	0,50 / 2,50	0,0015 USD	1,50 USD

Con ese mismo volumen, Haiku síncrono supone un ahorro estimado del 50 % frente a Sonnet 5 y del 66,7 % frente a Sonnet 4.6. Batch reduciría otro 50 % frente a Haiku síncrono, a cambio de procesamiento asíncrono. No son ahorros medidos en una comparación de calidad entre modelos.

Fuente: [precios oficiales de Anthropic](#) y [descuento de Message Batches](#).

Consumo observado

Ejecución n8n	Tokens de entrada	Tokens de salida	Costo IA calculado
231	730	295	0,002205 USD
234	732	287	0,002167 USD
Total	1.462	582	0,004372 USD

Fórmula: costo = tokens_entrada × 1 / 1.000.000 + tokens_salida × 5 / 1.000.000. Las métricas proceden de las respuestas de Anthropic de dos solicitudes aprobadas. Los duplicados se filtran antes de llamar al modelo.

Controles y alcance del presupuesto

Una llamada combina clasificación y redacción. El proyecto se limita a 2.000 caracteres, la salida a 600 tokens y las reglas se obtienen de Notion. El registro de Ejecuciones permite controlar consumo y costo agregado en el panel.

Estas cifras representan inferencia, no el costo total del servicio. No incluyen suscripciones de n8n, Google o Notion, tiempo de revisión humana, reintentos ni consumo que un fallo no haya permitido registrar. Los precios del proveedor pueden cambiar; actualizar la tarifa del cálculo cuando corresponda.